



# Машинное обучение




# Производная

$$\lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0} = f'(x_0)$$




# Производная

$$\lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0} = f'(x_0)$$




## Условие экстремума

Если точка  $x_0$  экстремум и в ней существует производная, то  $f'(x_0) = 0$



## Условие экстремума

Если точка  $x_0$  экстремум и в ней существует производная, то  $f'(x_0) = 0$




## Условие экстремума

- 1- Вычисляем производную функции
- 2- Приравниваем производную к нулю
- 3- Находим корни этого уравнения

# Производная


$$f(x) = (x - 6)^2$$



# Производная

$$f(x) = (x - 6)^2$$

$$\frac{\partial f}{\partial x} = 2(x - 6)$$





# Производная


$$f(x) = (x - 6)^2$$

$$\frac{\partial f}{\partial x} = 0$$

$$\frac{\partial f}{\partial x} = 2(x - 6)$$

$$2(x - 6) = 0$$

$$x = 6$$



# Градиент

Вектор частных производных

$$Q(a, \mathbb{X}) = \frac{1}{\ell} \sum_{i=1}^{\ell} (\boldsymbol{\theta}_1 x_{i1} + \dots + \boldsymbol{\theta}_d x_{id})^2$$


$$\nabla f(\mathbf{X}) = \left( \frac{\partial f}{\partial x_1}, \dots, \frac{\partial f}{\partial x_d} \right)$$

# Важное свойство

Вектор частных производных

$$\nabla f(X) = \left( \frac{\partial f}{\partial \theta_1}, \dots, \frac{\partial f}{\partial \theta_d} \right)$$

В какую сторону функция быстрее всего растёт?



## Важное свойство

Если точка  $x_0$  - экстремум, в ней существует производная, то

$$\nabla f(x_0) = \mathbf{0}$$

Если функция выпуклая, то экстремум один

MSE для линейной регрессии – выпуклая! (при некоторых условиях)

Метод наименьших квадратов

# Модель линейной регрессии

Модель

$$a(x) = \theta_0 x_0 + \theta_1 x_1 + \dots + \theta_d x_d$$

Функционал ошибки


$$Q(a, \mathbb{X}) = \frac{1}{\ell} \sum_{i=1}^{\ell} (a(x_i) - y_i)^2$$

Среднеквадратичная ошибка

Цель:


$$Q(a, \mathbb{X}) \rightarrow \min_{\theta}$$

## Метод наименьших квадратов (Ordinary least squares)




## Метод наименьших квадратов (Ordinary least squares)

$$a(x) = \theta_0 + \theta_1 x_1$$






## Метод наименьших квадратов (Ordinary least squares)




$$Q(a, \mathbb{X}) = \frac{1}{\ell} \sum_{i=1}^{\ell} (a(x_i) - y_i)^2 \rightarrow \min_{\boldsymbol{\theta}}$$

## Метод наименьших квадратов (Ordinary least squares)



$$Q(a, \mathbb{X}) = \frac{1}{\ell} \sum_{i=1}^{\ell} (a(x_i) - y_i)^2 \rightarrow \min_{\theta}$$

## Метод наименьших квадратов (Ordinary least squares)



$$\square + \square + \square + \square + \square \rightarrow \min_{\theta}$$

Суть МНК: в качестве оценок взять такие параметры  $\theta$ , при которых сумма квадратов ошибок прогноза  $Q$  минимальна

# Метод наименьших квадратов (Ordinary least squares)

Модель

$$a(x) = \theta_0 + \theta_1 x_1$$

Функционал ошибки

$$Q(a, \mathbb{X}) = \frac{1}{\ell} \sum_{i=1}^{\ell} (a(x_i) - y_i)^2 \rightarrow \min_{\theta}$$

## Метод наименьших квадратов (Ordinary least squares)

Функционал ошибки

$$Q = \frac{1}{\ell} \sum_{i=1}^{\ell} (y_i - \theta_0 + \theta_1 x_1)^2 \rightarrow \min_{\theta}$$

Нахождение производных

$$\frac{\partial Q}{\partial \theta_0}$$

$$\frac{\partial Q}{\partial \theta_1}$$

## Метод наименьших квадратов (Ordinary least squares)

Функционал ошибки

$$Q = \frac{1}{\ell} \sum_{i=1}^{\ell} (y_i - \theta_0 + \theta_1 x_1)^2 \rightarrow \min_{\theta}$$

Нахождение производных

$$\frac{\partial Q}{\partial \theta_0} = \sum_{i=1}^{\ell} 2(y_i - \theta_0 + \theta_1 x_i). \quad (1)$$

## Метод наименьших квадратов (Ordinary least squares)

Функционал ошибки

$$Q = \frac{1}{\ell} \sum_{i=1}^{\ell} (y_i - \theta_0 + \theta_1 x_1)^2 \rightarrow \min_{\theta}$$

Нахождение производных

$$\frac{\partial Q}{\partial \theta_0} = \sum_{i=1}^{\ell} 2(y_i - \theta_0 + \theta_1 x_i) \cdot (1)$$

$$\frac{\partial Q}{\partial \theta_1} = \sum_{i=1}^{\ell} 2(y_i - \theta_0 + \theta_1 x_i) \cdot (x_i)$$

## Метод наименьших квадратов (Ordinary least squares)

Нахождение производных

$$\frac{\partial Q}{\partial \theta_0} = 0$$

$$\frac{\partial Q}{\partial \theta_1} = 0$$

$$\begin{cases} \sum_{i=1}^{\ell} 2(y_i - \theta_0 + \theta_1 x_i) \cdot (1) = 0 \\ \sum_{i=1}^{\ell} 2(y_i - \theta_0 + \theta_1 x_i) \cdot (x_i) = 0 \end{cases}$$



Метод наименьших квадратов (Ordinary least squares)

$$\begin{cases} 2 \left( \theta_1 \sum_{i=1}^{\ell} x_i + \theta_0 \ell - \sum_{i=1}^{\ell} y_i \right) = 0 \\ 2 \left( \theta_1 \sum_{i=1}^{\ell} x_i^2 + \theta_0 \sum_{i=1}^{\ell} x_i - \sum_{i=1}^{\ell} x_i y_i \right) = 0 \end{cases}$$

Метод наименьших квадратов (Ordinary least squares)

$$\theta_0 = \frac{\sum_{i=1}^{\ell} y_i - \theta_1 \sum_{i=1}^{\ell} x_i}{n}$$

$$\theta_1 = \frac{\ell \sum_{i=1}^{\ell} x_i y_i - \sum_{i=1}^{\ell} x_i \cdot \sum_{i=1}^{\ell} y_i}{\ell \sum_{i=1}^{\ell} x_i^2 - \left(\sum_{i=1}^{\ell} x_i\right)^2}$$

## Метод наименьших квадратов (Ordinary least squares)

Функционал ошибки

$$Q = \frac{1}{\ell} \sum_{i=1}^{\ell} (y_i - \theta_0 + \theta_1 x_1 + \dots + \theta_d x_d)^2 \rightarrow \min_{\theta}$$

$$\begin{cases} \frac{\partial Q}{\partial \theta_0} = 0 \\ \vdots \\ \frac{\partial Q}{\partial \theta_d} = 0 \end{cases} \quad \longrightarrow \quad \begin{cases} \theta_0 \\ \vdots \\ \theta_d \end{cases}$$

## Линейная регрессия в векторном виде

## Функция потерь (Lost function)

Модель

$$a(x) = \langle \theta, x \rangle$$

Среднеквадратичная ошибка

$$Q(a, \mathbb{X}) = \frac{1}{\ell} \sum_{i=1}^{\ell} (\langle \theta, x \rangle - y_i)^2$$

Цель

$$\underset{\theta}{\text{minimize}} Q(a, \mathbb{X})$$

# Матрица

Матрица объектов-признаков

$$\mathbb{X} = \begin{pmatrix} x_{11} & x_{11} & \cdots & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{\ell 1} & x_{\ell 1} & \cdots & \cdots & x_{\ell d} \end{pmatrix} \in \mathbb{R}^{\ell \times d}$$

# Матрица

Матрица объектов-признаков

$$\mathbb{X} = \begin{pmatrix} x_{11} & x_{11} & \cdots & \cdots & x_{1d} \\ \textcolor{red}{x_{21}} & \textcolor{red}{x_{22}} & \cdots & \cdots & \textcolor{red}{x_{2d}} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{\ell 1} & x_{\ell 1} & \cdots & \cdots & x_{\ell d} \end{pmatrix} \in \mathbb{R}^{\ell \times d}$$

Объект и его признаки

# Матрица

Матрица объектов-признаков

$$\mathbb{X} = \begin{pmatrix} x_{11} & \mathbf{x_{11}} & \cdots & \cdots & x_{1d} \\ x_{21} & \mathbf{x_{22}} & \cdots & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ x_{\ell 1} & \mathbf{x_{\ell 1}} & \cdots & \cdots & x_{\ell d} \end{pmatrix} \in \mathbb{R}^{\ell \times d}$$

Значения признака на всех объектах



# Вектор

Вектор размера  $d$  тоже матрица

Вектор-строка:

$$\boldsymbol{\theta} = (\boldsymbol{\theta}_1, \dots, \boldsymbol{\theta}_d) \in \mathbb{R}^{1 \times d}$$

Вектор-столбец:

$$\boldsymbol{\theta} = \begin{pmatrix} \boldsymbol{\theta}_1 \\ \vdots \\ \boldsymbol{\theta}_d \end{pmatrix} \in \mathbb{R}^{d \times 1}$$

# Матричное умножение

$$A \in \mathbb{R}^{m \times k} \quad B \in \mathbb{R}^{k \times n}$$

$$AB = C \in \mathbb{R}^{m \times n}$$

$$C_{ij} = \sum_{p=1}^k a_{ip} b_{pj}$$

## Матричное умножение

$$\begin{pmatrix} 1 & 2 \\ 0 & 1 \\ 10 & 0 \end{pmatrix} * \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 2 \end{pmatrix} = \begin{pmatrix} & & \\ & & \\ & & \end{pmatrix}$$

## Матричное умножение

$$\begin{pmatrix} 1 & 2 \\ 0 & 1 \\ 10 & 0 \end{pmatrix} * \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 2 \end{pmatrix} = \begin{pmatrix} 1 & & \\ & & \\ & & \end{pmatrix}$$

$$1*1 + 2*0=1$$

## Матричное умножение

$$\begin{pmatrix} \boxed{1} & \boxed{2} \\ 0 & 1 \\ 10 & 0 \end{pmatrix} * \begin{pmatrix} 1 & \boxed{0} & 0 \\ 0 & \boxed{0} & 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 & \\ & & \\ & & \end{pmatrix}$$

$$1*0 + 2*0=0$$

## Матричное умножение

$$\begin{pmatrix} \boxed{1} & \boxed{2} \\ 0 & 1 \\ 10 & 0 \end{pmatrix} * \begin{pmatrix} 1 & 0 & \boxed{0} \\ 0 & 0 & \boxed{2} \end{pmatrix} = \begin{pmatrix} 1 & 0 & 4 \\ & & \\ & & \end{pmatrix}$$

$$1*0 + 2*2=4$$

## Матричное умножение

$$\begin{pmatrix} 1 & 2 \\ 0 & 1 \\ 10 & 0 \end{pmatrix} * \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 2 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 4 \\ 0 & & \\ & & \end{pmatrix}$$

$$0*1 + 1*0=0$$

## Применение линейной модели

$$a(x) = \langle \theta, x \rangle = \theta_0 x_0 + \theta_1 x_1 + \dots + \theta_d x_d$$

$$X = \begin{pmatrix} x_{11} & \cdots & x_{1d} \\ \vdots & \ddots & \vdots \\ x_{\ell 1} & \cdots & x_{\ell d} \end{pmatrix} \in \mathbb{R}^{\ell \times d}$$

$$\theta = \begin{pmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_d \end{pmatrix} \in \mathbb{R}^{d \times 1}$$

Результат применения линейной модели к выборке  $\mathbb{X}$

$$X\theta = \begin{pmatrix} x_{11} & \cdots & x_{1d} \\ \vdots & \ddots & \vdots \\ x_{\ell 1} & \cdots & x_{\ell d} \end{pmatrix} * \begin{pmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_d \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^d \theta_i x_{1i} \\ \sum_{i=2}^d \theta_i x_{2i} \\ \vdots \\ \sum_{i=1}^d \theta_i x_{\ell i} \end{pmatrix} = \begin{pmatrix} \langle \theta, x_1 \rangle \\ \langle \theta, x_2 \rangle \\ \vdots \\ \langle \theta, x_{\ell} \rangle \end{pmatrix}$$



# Вычисление ошибки

Функционал ошибки

$$Q(a, \mathbb{X}) = \frac{1}{\ell} \sum_{i=1}^{\ell} (\langle \boldsymbol{\theta}, \mathbf{x} \rangle - y_i)^2 \rightarrow \min_{\boldsymbol{\theta}}$$

Отклонения прогнозов от ответа

$$\mathbf{x}\boldsymbol{\theta} - \mathbf{y} = \begin{pmatrix} \langle \boldsymbol{\theta}, \mathbf{x}_1 \rangle - y_1 \\ \langle \boldsymbol{\theta}, \mathbf{x}_2 \rangle - y_2 \\ \vdots \\ \langle \boldsymbol{\theta}, \mathbf{x}_\ell \rangle - y_\ell \end{pmatrix}$$

# Вычисление ошибки

Евклидова норма:

$$\|z\| = \sqrt{\sum_{j=1}^n z_j^2}$$

$$\|z\|^2 = \sum_{j=1}^n z_j^2$$

Отклонения прогнозов от ответа

$$x\theta - y = \begin{pmatrix} \langle \theta, x_1 \rangle - y_1 \\ \langle \theta, x_2 \rangle - y_2 \\ \vdots \\ \langle \theta, x_\ell \rangle - y_\ell \end{pmatrix}$$

# Вычисление ошибки

Отклонения прогнозов от ответа

$$\mathbf{x}\theta - \mathbf{y} = \begin{pmatrix} \langle \theta, x_1 \rangle - y_1 \\ \langle \theta, x_2 \rangle - y_2 \\ \vdots \\ \langle \theta, x_\ell \rangle - y_\ell \end{pmatrix}$$

Среднеквадратичная ошибка

$$\frac{1}{\ell} \sum_{i=1}^{\ell} (\langle \theta, x_i \rangle - y_i)^2 = \frac{1}{\ell} \|\mathbf{x}\theta - \mathbf{y}\|^2$$

Цель:

$$\frac{1}{\ell} \|\mathbf{x}\theta - \mathbf{y}\|^2 \rightarrow \min_{\theta}$$

## Среднеквадратичная ошибка

MSE для линейной регрессии:

$$Q(a, \mathbb{X}) = \frac{1}{\ell} \sum_{i=1}^{\ell} (\theta_1 x_{i1} + \dots + \theta_d x_{id})^2$$

## Нормальные уравнения (Normal equation)

$$\frac{1}{\ell} \|\mathbf{x}\boldsymbol{\theta} - \mathbf{y}\|^2 \rightarrow \min_{\boldsymbol{\theta}}$$

Вычисление градиента

$$\nabla \frac{1}{\ell} \|\mathbf{x}\boldsymbol{\theta} - \mathbf{y}\|^2 = \frac{2}{\ell} \mathbf{X}^T (\mathbf{x}\boldsymbol{\theta} - \mathbf{y})$$

Приравнивание градиента к нулю

$$\frac{2}{\ell} \mathbf{X}^T (\mathbf{x}\boldsymbol{\theta} - \mathbf{y}) = \mathbf{0}$$

## Нормальные уравнения (Normal equation)

$$\theta = (X^T X)^{-1} X^T y$$

$\theta$  — вектор коэффициентов (весов) модели

$X^T$  — транспонированная матрица признаков

$y$  — вектор меток

## Нормальные уравнения (Normal equation)

$$\theta = (X^T X)^{-1} X^T y$$

$\theta$  — вектор коэффициентов (весов) модели

$X^T$  — транспонированная матрица признаков

$y$  — вектор меток

```
np.linalg.inv(X.T @ X) @ X.T @ Y
```

## Нормальные уравнения (Normal equation)

$$\theta = (X^T X)^{-1} X^T y$$

**у метода нормальных уравнений есть несколько проблем**

Высокая вычислительная сложность

Проблемы с обратимостью матрицы


Когда количество объектов меньше количества признаков



# Высокая вычислительная сложность

$$(X^T X)^{-1}$$

Вычисляется за  $O(d^3)$



Если процессор выполняет  $\sim 10^9$  операций / сек:

$d = 10 \rightarrow \sim 10^{-6}$  с микросекунды

$d = 100 \rightarrow \sim 10^{-3}$  с микросекунды

$d = 1000 \rightarrow 1$  с

$d = 10000 \rightarrow 1000$  с  $\sim 17$  минут

$d = 100000 \rightarrow \sim 10^6$  с  $\sim 11.6$  дней

## Проблемы с обратимостью матрицы

$$\theta = (X^T X)^{-1} X^T y$$

### Линейная зависимость признаков (мультиколлинеарность)

- Какой-то столбец  $X$ , линейная комбинация других, тогда  $\text{rank}(X) < \text{число признаков}$

Признак с нулевой дисперсией: столбец константа

## Проблемы с обратимостью матрицы

$$A^{-1}, \quad AA^{-1} = I$$

`np.linalg.inv`

Работает только для квадратных и невырожденных (полного ранга) матриц.

Если матрица вырожденная ( $\det = 0$ ), то `np.linalg.inv` выдаст ошибку `LinAlgError: Singular matrix`.

`np.linalg.pinv` (псевдообратную Мура–Пенроуза)

Определена для любых матриц: прямоугольных, сингулярных и плохо обусловленных.

Реализована через SVD (сингулярное разложение)

# Нормальные уравнения (Normal equation)

## Постановка

- Даны данные  $\{(x_i, y_i)\}_{i=1}^{\ell}$
- Соберём матрицу признаков  $X \in \mathbb{R}^{\ell \times d}$
- Вектор ответов  $y \in \mathbb{R}^{\ell}$
- Ищем все  $\theta \in \mathbb{R}^d$  для линейной модели

$$a(x) = \langle \theta, x \rangle$$

Функция качества (средняя квадратичная ошибка)

$$Q(\theta) = \frac{1}{\ell} (y - X\theta)^T (y - X\theta) = \frac{1}{\ell} \|y - X\theta\|_2^2 \rightarrow \min_{\theta}$$

# Нормальные уравнения (Normal equation)

## 1) Раскрываем скобки

- Используем тождества для скаляров :  $a^T x = x^T a$

$$\begin{aligned}(y - X\theta)^T(y - X\theta) &= y^T y - y^T X\theta - (X\theta)^T y + (X\theta)^T (X\theta) \\&= y^T y - y^T X\theta - \theta^T X^T y + \theta^T X^T X\theta \\&= y^T y - 2y^T X\theta + \theta^T X^T X\theta\end{aligned}$$

$y^T X\theta$  равно своему транспонированию  $(y^T X\theta)^T = \theta^T X^T y$

$$Q(\theta) = \frac{1}{\ell} (y^T y - 2y^T X\theta + \theta^T X^T X\theta)$$

# Нормальные уравнения (Normal equation)

## 2) Считаем градиент по $\theta$

- Правила матричного дифференцирования:

$$\nabla_{\theta}(b^T \theta) = b$$

$$\nabla_{\theta}(\theta^T b) = b$$

$$\nabla_{\theta}(\theta^T A \theta) = (A + A^T)\theta \text{ (в частности, если } A \text{ симметрична, то } = 2A\theta)$$

Здесь  $A = X^T X$  — симметрична.

$$\nabla_{\theta} Q(\theta) = \frac{1}{\ell} (\mathbf{0} - 2X^T y + 2X^T X \theta) = \frac{2}{\ell} (X^T X \theta - X^T y)$$

Эквивалентно можно запомнить короткое правило:  $\nabla_{\theta}(\|y - X\theta\|^2) = 2X^T(X\theta - y)$

# Нормальные уравнения (Normal equation)

## 2) Условие минимума (Нормальные уравнения)

- Ставим градиент равным нулю:

$$\frac{2}{\ell} (X^T X \theta - X^T y) = 0$$

$$X^T X \theta = X^T y$$

Это линейная система вида  $A\theta = b$  с  $A: X^T X, b := X^T y$

Если матрица  $A$  обратима, то умножаем на  $A^{-1}$

$$A^{-1} A \theta = A^{-1} b \Rightarrow \theta = A^{-1} b$$

$$\theta = (X^T X)^{-1} X^T y$$