



# Машинное обучение



# Классификация (Classification)



# Бинарная классификация

Это метод машинного обучения, который позволяет разделить данные на две категории

$$y \in \{-1, 1\}$$


Идентификация спама (Да / Нет)



Обнаружение мошеннических операций (Да / Нет)



Классификация опухолей (Доброкачественные / Злокачественные)




# Мультиклассовая классификация

Это метод машинного обучения, который позволяет разделить данные на несколько категорий

$y \in \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$

**Вход:** Изображение рукописного номера


**Выход:** Число



# Бинарная классификация

$$\mathbb{Y} \in \{-1, 1\}$$

- ⚡ -1 Отрицательный класс
- ⚡ 1 Положительный класс
- ⚡  $A(x)$  Должен возвращать одно из двух чисел




# Классификация (Classification)

⚡ Линейная регрессия

$$a(x) = \theta_0 + \sum_{i=1}^d \theta_i x_i$$

⚡ Вещественное число


$$-\infty \leq a(x) \leq +\infty$$



# Классификация (Classification)

$$a(x) = \theta_0 + \sum_{j=1}^d \theta_j x_j$$


|   | Class -1  | Class 1  |
|---|-----------|----------|
| 0 | -0.874904 | 1.308753 |
| 1 | -0.413640 | 1.199750 |
| 2 | -1.240367 | 0.653478 |
| 3 | 2.944008  | 1.246134 |
| 4 | -0.228938 | 0.641666 |
| 5 | -0.198273 | 0.540919 |
| 6 | -2.065783 | 1.182851 |
| 7 | -0.095081 | 1.580854 |
| 8 | -0.211104 | 0.729224 |
| 9 | -1.019285 | 0.979414 |



# Классификация (Classification)

$$a(x) = \theta_0 + \sum_{j=1}^d \theta_j x_j$$

|   | Class -1  | Class 1  |
|---|-----------|----------|
| 0 | -0.874904 | 1.308753 |
| 1 | -0.413640 | 1.199750 |
| 2 | -1.240367 | 0.653478 |
| 3 | 2.944008  | 1.246134 |
| 4 | -0.228938 | 0.641666 |
| 5 | -0.198273 | 0.540919 |
| 6 | -2.065783 | 1.182851 |
| 7 | -0.095081 | 1.580854 |
| 8 | -0.211104 | 0.729224 |
| 9 | -1.019285 | 0.979414 |






# Классификация (Classification)

$$a(x) = \theta_0 + \sum_{j=1}^d \theta_j x_j$$


|   | Class -1  | Class 1  |
|---|-----------|----------|
| 0 | -0.874904 | 1.308753 |
| 1 | -0.413640 | 1.199750 |
| 2 | -1.240367 | 0.653478 |
| 3 | 2.944008  | 1.246134 |
| 4 | -0.228938 | 0.641666 |
| 5 | -0.198273 | 0.540919 |
| 6 | -2.065783 | 1.182851 |
| 7 | -0.095081 | 1.580854 |
| 8 | -0.211104 | 0.729224 |
| 9 | -1.019285 | 0.979414 |



# Классификация (Classification)

$$a(x) = \theta_0 + \sum_{j=1}^d \theta_j x_j$$


|   | Class -1  | Class 1  |
|---|-----------|----------|
| 0 | -0.874904 | 1.308753 |
| 1 | -0.413640 | 1.199750 |
| 2 | -1.240367 | 0.653478 |
| 3 | 2.944008  | 1.246134 |
| 4 | -0.228938 | 0.641666 |
| 5 | -0.198273 | 0.540919 |
| 6 | -2.065783 | 1.182851 |
| 7 | -0.095081 | 1.580854 |
| 8 | -0.211104 | 0.729224 |
| 9 | -1.019285 | 0.979414 |



# Классификация (Classification)

$$a(x) = \text{sign} \left( \theta_0 + \sum_{j=1}^d \theta_j x_j \right)$$

|   | Class -1  | Class 1  |
|---|-----------|----------|
| 0 | -0.874904 | 1.308753 |
| 1 | -0.413640 | 1.199750 |
| 2 | -1.240367 | 0.653478 |
| 3 | 2.944008  | 1.246134 |
| 4 | -0.228938 | 0.641666 |
| 5 | -0.198273 | 0.540919 |
| 6 | -2.065783 | 1.182851 |
| 7 | -0.095081 | 1.580854 |
| 8 | -0.211104 | 0.729224 |
| 9 | -1.019285 | 0.979414 |



# Классификация (Classification)

## ⚡ Линейная регрессия

$$a(x) = \theta_0 + \sum_{j=1}^d \theta_j x_j$$

$$-\infty \leq a(x) \leq +\infty$$

$$a(x) = \langle \theta, x \rangle$$

## ⚡ Бинарная классификация

$$a(x) = \textit{sign}(\langle \theta, x \rangle)$$


$$a(x) = \begin{cases} -1 \\ +1 \end{cases}$$

# Классификация (Classification)


⚡ Уравнение гиперплоскости

$$\langle \theta, x \rangle = 0$$


$$\langle \theta, x \rangle = |\theta| \cdot |x| \cdot \cos \alpha = 0$$



# Классификация (Classification)



# Классификация (Classification)



# Классификация (Classification)


## Уравнение гиперплоскости

Если  $x$  **лежит** на гиперплоскости, то  
 $\langle \theta, x \rangle = 0$

$\langle \theta, x \rangle < 0$  объект **слева** от неё

$\langle \theta, x \rangle > 0$  объект **справа** от неё

$$\langle \theta, x \rangle = 0$$






Обучение модели

# Классификация (Classification)

## Отступы (Margin)

Расстояние от точки до гиперплоскости  $\langle \theta, x \rangle = 0$

$$\frac{|\langle \theta, x \rangle|}{\|\theta\|}$$




# Классификация (Classification)

## Отступы (Margin)

$$M_i = y_i \langle \theta, x_i \rangle$$

$M_i > 0$  классификатор дает верный ответ

$M_i < 0$  классификатор ошибается



# Обучение линейных классификаторов

## Функция потерь в классификации

Бинарная функция потерь

$$L(y, a) = [a \neq y]$$

Функционал ошибки - доля ошибок

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) \neq y_i]$$

⚡ Доля ошибок для линейного классификатора

$$a(x) = \textit{sign}(\langle \boldsymbol{\theta}, x \rangle)$$

Функционал ошибки:

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) \neq y_i] = \frac{1}{\ell} \sum_{i=1}^{\ell} [\textit{sign}(\langle \boldsymbol{\theta}, x_i \rangle) \neq y_i]$$

# Обучение линейных классификаторов

⚡ Доля ошибок для линейного классификатора

$$a(x) = \textit{sign}(\langle \boldsymbol{\theta}, x \rangle)$$

Функционал ошибки:

$$Q(a, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [a(x_i) \neq y_i] = \frac{1}{\ell} \sum_{i=1}^{\ell} [\textit{sign}(\langle \boldsymbol{\theta}, x_i \rangle) \neq y_i]$$

**Недифференцируемая функция**

## Отступы для линейного классификатора

Функционал ошибки:

$$Q(\theta, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [\textit{sign}(\langle \theta, x_i \rangle) \neq y_i]$$

## Отступы для линейного классификатора

Функционал ошибки:

$$Q(\theta, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [\text{sign}(\langle \theta, x_i \rangle) \neq y_i]$$

Альтернативная запись:

$$\mathbf{M}_i = y_i \langle \theta, x_i \rangle$$

$$Q(\theta, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} [y_i \langle \theta, x_i \rangle < 0]$$




# Обучение линейных классификаторов

## ⚡ Отступы для линейного классификатора

Функция потерь:

$$L(M) = [y_i \langle \theta, x_i \rangle < 0]$$

$$L(y, a(x)) = \begin{cases} 0 & \text{if } y = a(x) \\ 1 & \text{if } y \neq a(x) \end{cases}$$



# Обучение линейных классификаторов

## ⚡ Отступы для линейного классификатора


Функция потерь:

$$L(M) = [y_i \langle \theta, x_i \rangle < 0]$$

$$L(y, a(x)) = \begin{cases} 0 & \text{if } y = a(x) \\ 1 & \text{if } y \neq a(x) \end{cases}$$



$$L(M) = [y_i \langle \theta, x_i \rangle < 0] \leq \tilde{L}(y_i \langle \theta, x_i \rangle)$$




# Верхняя оценка


$$0 \leq \frac{1}{\ell} \sum_{i=1}^{\ell} [y_i \langle \theta, x_i \rangle < 0] \leq \frac{1}{\ell} \sum_{i=1}^{\ell} \tilde{L}(y_i \langle \theta, x_i \rangle) \rightarrow \min$$

Минимизируем верхнюю оценку




Надеемся, что она прижмёт долю ошибок к нулю



# Обучение линейных классификаторов






# Обучение линейных классификаторов



$$V(M) = \max(1 - M)$$

$$L(M) = \log_2(1 + e^{-M})$$



$$Q(M) = (1 - M)^2$$

$$S(M) = \frac{1}{(1 + e^M)}$$

$$E(M) = e^{-M}$$

# Обучение линейных классификаторов

## Квадратичная функция потерь


$$L_i(\theta) = (1 - M_i)^2 = (1 - \theta^T \cdot x_i \cdot y_i)^2$$

$$Q(\theta) = \sum_{i=1}^{\ell} (1 - \theta^T \cdot x_i \cdot y_i)^2 \rightarrow \min_{\theta}$$

$$\frac{\partial Q(\theta)}{\partial \theta} = -2 \cdot \sum_{i=1}^{\ell} (1 - \theta^T \cdot x_i \cdot y_i) \cdot x_i^T \cdot y_i = 0$$

$$\sum_{i=1}^{\ell} x_i^T \cdot y_i - \theta^T \cdot \sum_{i=1}^{\ell} x_i \cdot x_i^T \cdot y_i^2 = 0$$

$$\theta^T = \sum_{i=1}^{\ell} x_i^T \cdot y_i \cdot \left( \sum_{i=1}^{\ell} x_i \cdot x_i^T \right)^{-1}$$



## Градиентный спуск

Выбираем логистическую функцию потерь:

$$Q(\theta, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} \log(1 + e^{-y_i \langle \theta, x_i \rangle}) \rightarrow \min_{\theta}$$

Вычисляем градиент:

$$\nabla_{\theta} Q(\theta, X) = -\frac{1}{\ell} \sum_{i=1}^{\ell} \frac{x_i y_i}{1 + e^{(y_i \langle \theta, x_i \rangle)}}$$

Делаем градиентный спуск:

$$\theta^{(t)} = \theta^{(t-1)} + \alpha \frac{1}{\ell} \sum_{i=1}^{\ell} \frac{x_i y_i}{1 + e^{(y_i \langle \theta, x_i \rangle)}}$$



## Градиентный спуск

Выбираем логистическую функцию потерь:

$$Q(\theta, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} \log(1 + e^{-y_i \langle \theta, x_i \rangle}) \rightarrow \min_{\theta}$$

Вычисляем градиент:

$$\nabla_{\theta} Q(\theta, X) = -\frac{1}{\ell} \sum_{i=1}^{\ell} \frac{x_i y_i}{1 + e^{(y_i \langle \theta, x_i \rangle)}}$$

Делаем градиентный спуск:


$$\theta^{(t)} = \theta^{(t-1)} + \alpha \frac{1}{\ell} \sum_{i=1}^{\ell} \frac{x_i y_i}{1 + e^{(y_i \langle \theta, x_i \rangle)}}$$

# Обучение линейных классификаторов


## ⚡ Пример регуляризации

$$Q(\theta, X) = \frac{1}{\ell} \sum_{i=1}^{\ell} \log(1 + e^{-y_i \langle \theta, x_i \rangle}) \rightarrow \min_{\theta}$$


$$\frac{1}{\ell} \sum_{i=1}^{\ell} \log(1 + e^{-y_i \langle \theta, x_i \rangle}) + \lambda \|\theta\|_2 \rightarrow \min_{\theta}$$




# Классификация (Classification)




# Классификация (Classification)




# Классификация (Classification)



# Классификация (Classification)




# Классификация (Classification)



Если  $a(x) = \text{sign}(\langle \theta, x \rangle - t) \geq 0.5 \rightarrow y = 1$


Если  $a(x) = \text{sign}(\langle \theta, x \rangle - t) \leq 0.5 \rightarrow y = 0$

# Классификация (Classification)





# Классификация (Classification)



# Классификация (Classification)


$$a(x) = \textit{sign}(\langle \theta, x \rangle)$$

Вероятность - это число на отрезке  $[0;1]$




В логистической регрессии для предсказания вероятности используется **сигмоида**

$$a(x) = \sigma(\langle \theta, x \rangle)$$

где  $\sigma = \frac{1}{1 + e^{-\langle \theta, x \rangle}}$



# Логистическая регрессия



Метод максимального правдоподобия

## Задача о музее

А как часто музей работает?

Гипотезы:

Музей работает раз в год

Музей работает каждый выходной

Музей работает всегда



## Задача о музее

А как часто музей работает?

Гипотезы:

Музей работает раз в год

Музей работает каждый выходной

Музей работает всегда



Вероятности:

$$\frac{1}{365}$$

$$\frac{1}{3}$$

$$1$$

# Метод максимального правдоподобия

Параметр  $\theta$  — Работоспособность музеё

Наблюдение  $x_1$  — сегодня музей работал

Задача: Максимизировать вероятность появления выборки по значению  $\theta$

$$\mathbb{P}(x_1 = \text{работает} | \theta) \rightarrow \max_{\theta}$$

# Метод максимального правдоподобия

Параметр  $\theta$  — Работоспособность музеё

Наблюдение  $x_1$  — сегодня музей работал

Задача: Максимизировать вероятность появления выборки по значению  $\theta$

$$\mathbb{P}(x_1 = \text{работает} | \theta) \rightarrow \max_{\theta}$$

$$\mathbb{P}(x_1 = \text{работает} | \theta = \text{раз в году}) = \frac{1}{365}$$

$$\mathbb{P}(x_1 = \text{работает} | \theta = \text{по выходным}) = \frac{1}{3}$$

$$\mathbb{P}(x_1 = \text{работает} | \theta = \text{каждый день}) = 1$$



# Правдоподобие

Правдоподобие (likelihood function)- вероятность получить наблюдаемую выборку при конкретном значении параметра

Оценка максимального правдоподобия – значение параметра, которое максимизирует правдоподобие

# Правдоподобие

Функция  $f(x)$



$X$

Выборка:  $x_1, x_2, \dots, x_n$

Предположение: Выборка пришла из распределения с плотностью  $f(x | \theta)$

Параметр  $\theta$  нам не известен и хотим оценить по выборке

# Правдоподобие

$$L(\theta \mid x_1, \dots, x_n) = \mathbb{P}(x_1, \dots, x_n \mid \theta) = f(x_1, \dots, x_n \mid \theta)$$

$$= f(x_1 \mid \theta) \cdot f(x_2 \mid \theta) \cdot \dots \cdot f(x_n \mid \theta)$$

$$= \prod_{i=1}^n f(x_i \mid \theta)$$

# Метод максимального правдоподобия

Метод максимального правдоподобия состоит в выборе в качестве оценки  $\theta$  значения, при котором правдоподобие достигает максимума:

$$L(\theta \mid x_1, \dots, x_n) = \prod_{i=1}^n f(x_i \mid \theta) \rightarrow \max_{\theta}$$

Оценка максимального правдоподобия (maximum likelihood estimation)

$$\theta^{MLE} = \operatorname{argmax}_{\theta} L(\theta \mid x_1, \dots, x_n)$$

# Метод максимального правдоподобия

Максимизация функции  $L(\theta)$  равносильна максимизации функции  $\ln L(\theta)$

$$\ln L(\theta \mid x_1, \dots, x_n) = \sum_{i=1}^n \ln f(x_i \mid \theta) \rightarrow \max_{\theta}$$

Возьмём производную и приравняем её к нулю:

$$\frac{\partial \ln L}{\partial \theta} = \sum_{i=1}^n \frac{\partial \ln f(x_i \mid \theta)}{\partial \theta} = 0$$

Решив это уравнение, получим оценку максимального правдоподобия

## Распределение Бернулли

## Метод максимального правдоподобия

$$a(x) = \underset{\theta}{\operatorname{argmax}} P(y|x, \theta)$$

В общем случае для всей обучающей выборки

$$P(y_1, y_2, \dots, y_n | x_1, x_2, \dots, x_n, \theta_1, \theta_2, \dots, \theta_d)$$

Наивный байесовский классификатор (Naïve Bayes classifier)

$$L(\theta) = \prod_{i=1}^n P(y_i | x_i, \theta)$$

# Распределение Бернулли

$$x_i = \begin{cases} 1, \text{ если любит кофе} \\ 0, \text{ если не любит кофе} \end{cases}$$

| $x_i$                 | 0          | 1      |
|-----------------------|------------|--------|
| $\mathbb{P}(x_i = k)$ | $1 - \rho$ | $\rho$ |



# Распределение Бернулли

$$x_i = \begin{cases} 1, \text{ если любит кофе} \\ 0, \text{ если не любит кофе} \end{cases}$$

$$x_1 = 1, x_2 = 0, x_3 = 1, \dots, x_n = 0$$

| $x_i$                 | 0          | 1      |
|-----------------------|------------|--------|
| $\mathbb{P}(x_i = k)$ | $1 - \rho$ | $\rho$ |

# Распределение Бернулли

$$x_i = \begin{cases} 1, \text{ если любит кофе} \\ 0, \text{ если не любит кофе} \end{cases}$$

$$x_1 = 1, x_2 = 0, x_3 = 1, \dots, x_n = 0$$

Задача : найти ML-оценку для  $\rho$

$$L(\rho | x_1, \dots, x_n) = \mathbb{P}(x_1, \dots, x_n | \rho)$$

| $x_i$                 | 0          | 1      |
|-----------------------|------------|--------|
| $\mathbb{P}(x_i = k)$ | $1 - \rho$ | $\rho$ |

# Распределение Бернулли

$$x_i = \begin{cases} 1, \text{ если любит кофе} \\ 0, \text{ если не любит кофе} \end{cases}$$

| $x_i$                 | 0          | 1      |
|-----------------------|------------|--------|
| $\mathbb{P}(x_i = k)$ | $1 - \rho$ | $\rho$ |

$$x_1 = 1, x_2 = 0, x_3 = 1, \dots, x_n = 0$$

Задача : найти ML-оценку для  $\rho$

$$\begin{aligned} L(\rho | x_1, \dots, x_n) &= \mathbb{P}(x_1, \dots, x_n | \rho) \\ &= \mathbb{P}(x_1 | \rho) \cdot \mathbb{P}(x_2 | \rho) \cdot \mathbb{P}(x_3 | \rho) \cdot \dots \cdot \mathbb{P}(x_d | \rho) \end{aligned}$$

# Распределение Бернулли

$$x_i = \begin{cases} 1, \text{ если любит кофе} \\ 0, \text{ если не любит кофе} \end{cases}$$

| $x_i$                 | 0          | 1      |
|-----------------------|------------|--------|
| $\mathbb{P}(x_i = k)$ | $1 - \rho$ | $\rho$ |

$$x_1 = 1, x_2 = 0, x_3 = 1, \dots, x_n = 0$$

Задача : найти ML-оценку для  $\rho$

$$L(\rho | x_1, \dots, x_n) = \mathbb{P}(x_1, \dots, x_n | \rho)$$

$$= \mathbb{P}(x_1 | \rho) \cdot \mathbb{P}(x_2 | \rho) \cdot \mathbb{P}(x_3 | \rho) \cdot \dots \cdot \mathbb{P}(x_d | \rho)$$

$$= \rho \cdot (1 - \rho) \cdot \rho \cdot \dots \cdot (1 - \rho) =$$

# Распределение Бернулли

$$x_i = \begin{cases} 1, \text{ если любит кофе} \\ 0, \text{ если не любит кофе} \end{cases}$$

| $x_i$                 | 0          | 1      |
|-----------------------|------------|--------|
| $\mathbb{P}(x_i = k)$ | $1 - \rho$ | $\rho$ |

$$x_1 = 1, x_2 = 0, x_3 = 1, \dots, x_n = 0$$

Задача : найти ML-оценку для  $\rho$

$$L(\rho | x_1, \dots, x_n) = \mathbb{P}(x_1, \dots, x_n | \rho)$$

$$= \mathbb{P}(x_1 | \rho) \cdot \mathbb{P}(x_2 | \rho) \cdot \mathbb{P}(x_3 | \rho) \cdot \dots \cdot \mathbb{P}(x_d | \rho)$$

$$= \rho \cdot (1 - \rho) \cdot \rho \cdot \dots \cdot (1 - \rho) =$$

$$\rho^{\sum x_i} \cdot (1 - \rho)^{n - \sum x_i} \rightarrow \max_{\rho}$$

# Распределение Бернулли

$$x_i = \begin{cases} 1, \text{ если любит кофе} \\ 0, \text{ если не любит кофе} \end{cases}$$

| $x_i$                 | 0          | 1      |
|-----------------------|------------|--------|
| $\mathbb{P}(x_i = k)$ | $1 - \rho$ | $\rho$ |

$$x_1 = 1, x_2 = 0, x_3 = 1, \dots, x_n = 0$$

Задача : найти ML-оценку для  $\rho$

$$L(\rho | x_1, \dots, x_n) = \mathbb{P}(x_1, \dots, x_n | \rho)$$

$$= \mathbb{P}(x_1 | \rho) \cdot \mathbb{P}(x_2 | \rho) \cdot \mathbb{P}(x_3 | \rho) \cdot \dots \cdot \mathbb{P}(x_d | \rho)$$

$$= \rho \cdot (1 - \rho) \cdot \rho \cdot \dots \cdot (1 - \rho) =$$

$$\rho^{\sum x_i} \cdot (1 - \rho)^{n - \sum x_i} \rightarrow \max_{\rho}$$

Прологарифмируем:

$$\ln L = \sum x_i \cdot \ln \rho + \left( n - \sum x_i \right) \cdot \ln(1 - \rho) \rightarrow \max_{\rho}$$

Прологарифмируем:

$$\ln L = \sum x_i \cdot \ln \rho + \left( n - \sum x_i \right) \cdot \ln(1 - \rho) \rightarrow \max_{\rho}$$

Возьмём производную:

$$\frac{\partial \ln L}{\partial p} = \frac{\sum x_i}{p} - \frac{(n - \sum x_i)}{1 - p}$$

Прологарифмируем:

$$\ln L = \sum x_i \cdot \ln \rho + \left( n - \sum x_i \right) \cdot \ln(1 - \rho) \rightarrow \max_{\rho}$$

Возьмём производную:

$$\frac{\partial \ln L}{\partial p} = \frac{\sum x_i}{p} - \frac{(n - \sum x_i)}{1 - p}$$

$$\frac{\sum x_i}{\hat{p}} - \frac{(n - \sum x_i)}{1 - \hat{p}} = 0$$



Прологарифмируем:

$$\ln L = \sum x_i \cdot \ln \rho + \left( n - \sum x_i \right) \cdot \ln(1 - \rho) \rightarrow \max_{\rho}$$

Возьмём производную:

$$\frac{\partial \ln L}{\partial p} = \frac{\sum x_i}{p} - \frac{(n - \sum x_i)}{1 - p}$$

$$\frac{\sum x_i}{\hat{p}} - \frac{(n - \sum x_i)}{1 - \hat{p}} = 0$$

$$\sum x_i - \hat{p} \cdot \sum x_i = n \cdot \hat{p} - \hat{p} \cdot \sum x_i$$

Прологарифмируем:

$$\ln L = \sum x_i \cdot \ln \rho + \left( n - \sum x_i \right) \cdot \ln(1 - \rho) \rightarrow \max_{\rho}$$

Возьмём производную:

$$\frac{\partial \ln L}{\partial p} = \frac{\sum x_i}{p} - \frac{(n - \sum x_i)}{1 - p}$$

$$\frac{\sum x_i}{\hat{p}} - \frac{(n - \sum x_i)}{1 - \hat{p}} = 0$$

$$\sum x_i - \cancel{\hat{p} \cdot \sum x_i} = n \cdot \hat{p} - \cancel{\hat{p} \cdot \sum x_i}$$

Прологарифмируем:

$$\ln L = \sum x_i \cdot \ln \rho + \left( n - \sum x_i \right) \cdot \ln(1 - \rho) \rightarrow \max_{\rho}$$

Возьмём производную:

$$\frac{\partial \ln L}{\partial p} = \frac{\sum x_i}{p} - \frac{(n - \sum x_i)}{1 - p}$$

$$\frac{\sum x_i}{\hat{p}} - \frac{(n - \sum x_i)}{1 - \hat{p}} = 0$$

$$\sum x_i - \cancel{\hat{p} \cdot \sum x_i} = n \cdot \hat{p} - \cancel{\hat{p} \cdot \sum x_i}$$

$$\hat{p}^{ML} = \frac{1}{n} \sum x_i = \bar{x}$$

# Метод максимального правдоподобия

## Пример

Пусть у нас монета, вероятность орла  $\rho$ , Каждый опыт  $X_i \in \{0,1\}$

$X_i = 1$  орёл и  $X_i = 0$  решка



## Распределение

$$\mathbb{P}(X_i = x_i | \rho) = \rho^{x_i}(1 - \rho)^{1-x_i}$$

# Метод максимального правдоподобия

Распределение

$$\mathbb{P}(X_i = x_i \mid \rho) = \rho^{x_i}(1 - \rho)^{1-x_i}$$

**Шаг 1.** Запишем правдоподобие для выборки  $X_1, \dots, X_n$

$$L(\rho \mid x_1, \dots, x_n) = \prod_{i=1}^n \rho^{x_i}(1 - \rho)^{1-x_i}$$

Обозначим  $k = \sum_{i=1}^n X_i$  сколько раз выпал орёл

$$L(\rho \mid x_1, \dots, x_n) = \rho^k(1 - \rho)^{n-k}$$

**Шаг 2.** Логарифм правдоподобия


$$\ell(\rho) = \ln L(\rho) = k \ln \rho + (n - k) \ln(1 - \rho)$$

**Шаг 3.** Берём производную и приравниваем к нулю

$$\frac{\partial \ell}{\partial \rho} = \frac{k}{\rho} - \frac{n - k}{1 - \rho} = 0$$

$$\frac{k}{\rho} = \frac{n-k}{1-\rho} \Rightarrow k(1 - \rho) = \rho(n - k) \Rightarrow k - k\rho = n\rho - k\rho \Rightarrow k = n\rho \Rightarrow \hat{\rho}^{MLE} = \frac{k}{n}$$

# Обучение линейных классификаторов



# Square loss

Модель

$$a(x) = \sigma(\theta_0 x_0 + \theta_1 x_1 + \dots + \theta_d x_d) = \sigma(\langle \theta, x \rangle)$$


Функция потерь

$L(a(x), y) = (a(x) - y(x))^2$  — квадратичная ошибка

$$L_{MSE} = (y_i - x_i^T \theta)^2 = \frac{(y_i^2 - y_i \cdot x_i^T \theta)^2}{y_i^2} = (1 - y_i \cdot x_i^T \theta)^2$$

$$Q(M) = (1 - M)^2$$

# Square loss




$$Q(M) = (1 - M)^2$$



# Square loss

| М   | Смысл                           | $(1 - M)^2$ |
|-----|---------------------------------|-------------|
| -2  | сильная ошибка                  | 9           |
| -2  | ошибка                          | 4           |
| 0   | ровно на границе, очень плохо   | 1           |
| 0.5 | правильный, но близко к границе | 0.25        |
| 1   | минимум потерь                  | 0           |
| 2   | очень уверенно правильно        | 1           |
| 3   | ещё более уверенно правильно    | 4           |
| 5   | супер-уверенно правильно        | 16          |



## Бинарная классификация

$$a(x) = \sigma(\langle \theta, x \rangle)$$

## Метод максимального правдоподобия

$$P(y|x, \theta)$$

$$a(x) = \underset{\theta}{\operatorname{argmax}} P(y|x, \theta)$$

$$L(\theta) = \prod_{i=1}^n P(y_i|x_i, \theta)$$

## Метод максимального правдоподобия

$$a(x) = \underset{\theta}{\operatorname{argmax}} P(y|x, \theta)$$

В общем случае для всей обучающей выборки

$$P(y_1, y_2, \dots, y_n | x_1, x_2, \dots, x_n, \theta_1, \theta_2, \dots, \theta_d)$$

Наивный байесовский классификатор (Naïve Bayes classifier)

$$L(\theta) = \prod_{i=1}^n P(y_i | x_i, \theta)$$

## Интерпретация вывода гипотезы

$$p(y = 1|x; \theta) = \sigma(\langle \theta, x \rangle)$$

$$p(y = 0|x; \theta) = 1 - \sigma(\langle \theta, x \rangle)$$

$$\left. \begin{array}{l} p(y = 1|x; \theta) = \sigma(\langle \theta, x \rangle) \\ p(y = 0|x; \theta) = 1 - \sigma(\langle \theta, x \rangle) \end{array} \right\} p(y|x; \theta) = \sigma(\langle \theta, x \rangle)^y (1 - \sigma(\langle \theta, x \rangle))^{1-y}$$

## Функция правдоподобия

$$L(\theta) = p(Y|X; \theta) = \prod_{i=0}^m p(y^{(i)} | x^{(i)}; \theta) = \prod_{i=1}^m \sigma(\theta^T x^{(i)})^{y^{(i)}} (1 - \sigma(\theta^T x^{(i)}))^{1-y^{(i)}}$$

# Логистическая регрессия

Логарифм функции правдоподобия

$$L(\theta) = \log L(\theta) = \log \prod_{i=1}^n \sigma(\theta^T \mathbf{x}^{(i)})^{y^{(i)}} (1 - \sigma(\theta^T \mathbf{x}^{(i)}))^{1-y^{(i)}}$$

$$\log_a bc = \log_a b + \log_a c$$

Логарифм функции правдоподобия

$$\begin{aligned} L(\theta) &= \log L(\theta) = \log \prod_{i=1}^n \sigma(\theta^T \mathbf{x}^{(i)})^{y^{(i)}} (1 - \sigma(\theta^T \mathbf{x}^{(i)}))^{1-y^{(i)}} \\ &= \sum_{i=1}^n \log(\sigma(\theta^T \mathbf{x}^{(i)})^{y^{(i)}} + \log(1 - \sigma(\theta^T \mathbf{x}^{(i)}))^{1-y^{(i)}}) \end{aligned}$$

$$\log_a b^c = c \cdot \log_a b$$

## Логарифм функции правдоподобия

$$L(\theta) = \log L(\theta) = \log \prod_{i=1}^n \sigma(\theta^T \mathbf{x}^{(i)})^{y^{(i)}} (1 - \sigma(\theta^T \mathbf{x}^{(i)}))^{1-y^{(i)}}$$

$$= \sum_{i=1}^n \log(\sigma(\theta^T \mathbf{x}^{(i)})^{y^{(i)}} + \log(1 - \sigma(\theta^T \mathbf{x}^{(i)}))^{1-y^{(i)}})$$

$$= \sum_{i=1}^m y^{(i)} \log \sigma(\theta^T \mathbf{x}^{(i)}) + (1 - y^{(i)}) \log(1 - \sigma(\theta^T \mathbf{x}^{(i)}))$$

## Логарифм функции правдоподобия

$$\mathbf{L}(\boldsymbol{\theta}) = \sum_{i=1}^m y^{(i)} \log \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)}) + (1 - y^{(i)}) \log(1 - \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)}))$$

$$-\mathbf{L}(\boldsymbol{\theta}) = \sum_{i=1}^m -y^{(i)} \log \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)}) - (1 - y^{(i)}) \log(1 - \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)}))$$



## Логарифм функции правдоподобия

$$\mathbf{L}(\boldsymbol{\theta}) = \sum_{i=1}^m -y^{(i)} \log \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)}) - (1 - y^{(i)}) \log(1 - \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)}))$$

## Функция потерь

$$\frac{\partial L}{\partial \boldsymbol{\theta}} = \sum_{i=1}^m y^{(i)} \mathbf{x}^{(i)} (1 - \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)})) \quad \frac{\partial L}{\partial \boldsymbol{\theta}} = \sum_{i=1}^m (y^{(i)} - 1) \mathbf{x}^{(i)} \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)})$$

$$\frac{\partial L}{\partial \boldsymbol{\theta}} = \sum_{i=1}^m y^{(i)} \mathbf{x}^{(i)} (1 - \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)})) + \sum_{i=1}^m (y^{(i)} - 1) \mathbf{x}^{(i)} \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)})$$

$$\frac{\partial L}{\partial \boldsymbol{\theta}} = \sum_{i=1}^m \mathbf{x}^{(i)} (y^{(i)} - \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)}))$$

Логарифм функции правдоподобия

$$\mathbf{L}(\boldsymbol{\theta}) = \sum_{i=1}^m -y^{(i)} \log \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)}) - (1 - y^{(i)}) \log(1 - \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)}))$$

Градиент

$$\nabla Q(\boldsymbol{\theta}) = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathbf{x}^{(i)} (y^{(i)} - \sigma(\boldsymbol{\theta}^T \mathbf{x}^{(i)}))$$



Сдвигаемся по антиградиенту

$$\boldsymbol{\theta}^t = \boldsymbol{\theta}^{t-1} - \alpha \nabla Q(\boldsymbol{\theta}^{t-1})$$

# Логистическая регрессия

Функция потерь:

$$Cost(a(x), y) = \begin{cases} -\log(a(x)), & y = 1 \\ -\log(1 - a(x)), & y = 0 \end{cases}$$



# Логистическая регрессия

Функция потерь:

$$Q(\theta, X) = \sum_{i=1}^n Q(a(x^{(i)}), y^{(i)})$$

$$Q(a(x^{(i)}), y^{(i)}) = -y^{(i)}\log(a(x^{(i)})) + (1 - y^{(i)})\log(1 - a(x^{(i)}))$$

